Lab 2 - Group 45

Lara Faria (106059), Tiago Santos (106329)

Questão 1

A melhor ação a em cada estado s é dada pela *optimal policy* π^* e é aquela que minimiza o *expected cost-to-go*. Esta é determinada pelo Operador de Otimalidade de Bellman, que pondera o custo imediato e o valor esperado dos estados futuros, ajustados pelo fator de desconto γ:

$$\pi^*(s) = \arg\min_{a \in \mathcal{A}} \left[C(s,a) + \gamma \sum_{s' \in \mathcal{X}} P_a(s'|s) V^*(s') \right]$$

Uma política π_1 é preferível a π_2 se o seu *expected cost-to-go* for menor ou igual para todos os estados do sistema, ou seja:

$$V^{\pi_1}(s) \leq V^{\pi_2}(s), \quad \forall s \in \mathcal{X}$$

Ambas as soluções utilizam a mesma métrica: o *expected discounted cost-to-go*, no entanto a primeira funciona como uma regra de decisão para extrair a melhor ação, enquanto a segunda estabelece o critério de ordenação para avaliar o desempenho relativo entre *policies*.

Questão 2

A análise dos resultados demonstra que ambos os métodos são eficazes, convergindo para valores de *cost-to-go* ($V(s)$) virtualmente idênticos em todos os estados (Figura 1). Esta convergência para os mesmos valores numéricos confirma a correção das implementações e a existência de uma política ótima consistente para o MDP formulado.

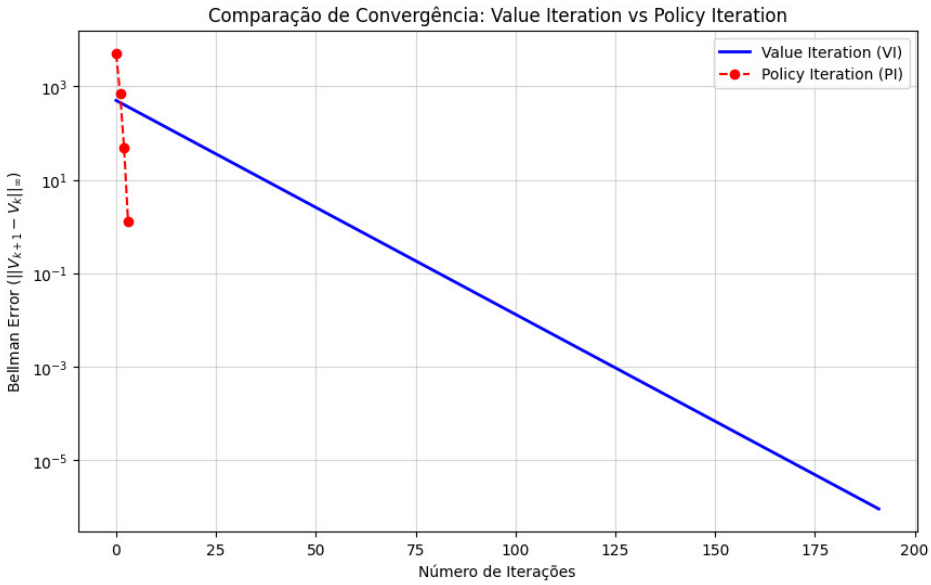

Figura 1: Gráfico da evolução do erro de Bellman em função do número de iterações

No que diz respeito à velocidade de convergência, a Policy Iteration revelou-se drasticamente mais rápida em termos do número de iterações necessárias. Como se pode observar no gráfico (Figura 2), a

Policy Iteration estabiliza em 4 iterações, enquanto o Value Iteration requer 192 iterações para atingir o mesmo nível de precisão (1×10^{-8}). Esta diferença deve-se à natureza dos algoritmos: enquanto o Value Iteration propaga a informação de custo de forma incremental através do fator de desconto γ, a Policy Iteration resolve o sistema linear da política atual de uma só vez em cada passo de avaliação, permitindo "saltos"muito maiores em direção à solução ótima.

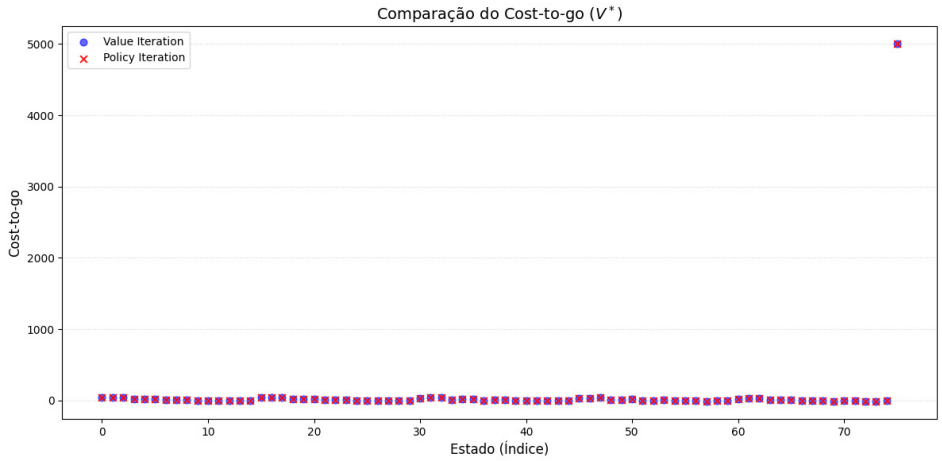

Figura 2: Comparação dos valores cost-to-go obtidos nos dois algoritmos

A escolha entre os dois métodos depende do equilíbrio entre simplicidade e custo computacional. O Value Iteration apresenta como principal vantagem a simplicidade de implementação, exigindo apenas operações básicas de álgebra linear (multiplicações matriz-vetor), o que o torna muito robusto e leve por iteração. No entanto, a sua desvantagem reside na lentidão de convergência, como pode ser observado, especialmente em problemas com fatores de desconto próximos de 1, onde a propagação do valor é muito demorada (valor utilizado foi de $\gamma = 0.9$).
Por outro lado, o Policy Iteration tem a grande vantagem de convergir num número de passos extremamente reduzido, muitas vezes encontrando a política ótima em apenas 4 ou 5 iterações. A sua desvantagem é o elevado custo computacional de cada iteração individual, uma vez que a fase de Policy Evaluation exige a inversão de uma matriz ou a resolução de um sistema de equações lineares com dimensão igual ao número de estados. Para o sistema de 76 estados aqui analisado, o custo da inversão é negligenciável, tornando o PI o método mais eficiente. Contudo, em problemas com milhares de estados, esta operação pode tornar-se proibitiva, favorecendo novamente o uso do VI.

Questão 3

Para analisar o impacto da função de custo, foram implementados quatro cenários distintos:

- **Cenário Base:** Representa o caso base descrito no enunciado.
- **Grande Penalização de Falha:** Simula um sistema crítico onde a falha (estado 75) é catastrófica ($R_{fail} = 50.000$).
- **Exportação Muito Lucrativa:** Cenário onde vender energia é altamente recompensado ($c_{ae} = -500$), incentivando comportamentos de risco.
- **Energia de Rede Muito Cara:** Cenário onde o uso da rede é fortemente penalizado ($c_{ac} = 1.000$), forçando a dependência de recursos solares.

As entradas abaixo representam o custo imediato das ações para os estados selecionados $[C(s, AC), C(s, AS), C(s, AE)]$ em cada cenário:

Cenário	**0**	**5**	**32**	**49**	**75**
Base	10	0	10	-5	500
Grande Penalização de falha	10	0	10	-5	50000
Exportação muito lucrativa	10	10	10	-500	500
Energia de rede muito cara	0	0	0	-5	500

Tabela 1: Funções de custo

A magnitude dos custos influencia diretamente o esforço necessário para o Value Iteration convergir para a função de valor ótima V^*, dado um critério de paragem fixo de $\epsilon = 10^{-6}$.
A taxa de convergência é teoricamente ditada por $\gamma = 0,9$. Contudo, o número total de iterações aumentou significativamente no cenário de Grande Penalização de Falha (235 iterações vs. 192 no Base). Isto deve-se ao facto de o erro inicial de Bellman ser muito superior devido à magnitude de r_{fail}. O tempo para atingir o threshold de 0,1 também foi superior neste cenário (125 iterações), refletindo uma maior inércia numérica inicial.

Cenário	**Nr de iterações**	**Nr de iterações até erro=0.1**
Base	192	81
Grande Penalização de falha	235	125
Exportação muito lucrativa	192	81
Energia de rede muito cara	192	81

Tabela 2: Comparação do número de iterações

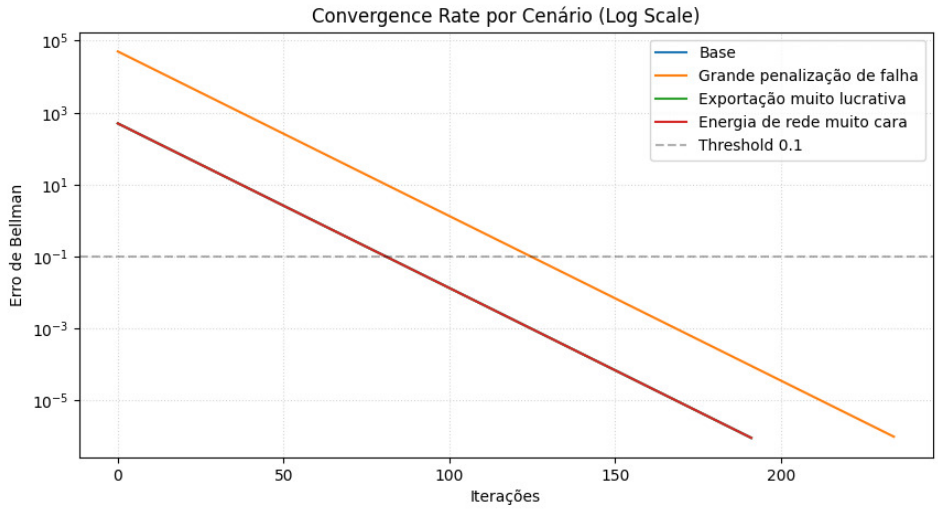

Figura 3: Convergence Rate por Cenário

- **Grande Penalização de Falha (Similaridade 100,0%):** A política permanece idêntica ao cenário Base, ou seja, penalizar ainda mais a falha apenas aumenta os valores dos estados sem alterar a melhor ação.
- **Exportação Muito Lucrativa (Similaridade 56,6%):** Este cenário induziu a mudança mais drástica. O agente torna-se "ganancioso", priorizando a venda de energia mesmo em estados de bateria mais baixa, desde que a recompensa esperada compense o risco de falha futura.
- **Energia de Rede Muito Cara (Similaridade 84,2%):** O agente muda para uma política de autossuficiência. Ao evitar o custo de rede de 1.000, o agente prefere esperar pela recarga solar (AS) em estados onde anteriormente utilizaria a rede (AC).

Cenário	**Diferenças (nr estados)**	**Similaridade %**
Base	0	100%
Grande Penalização de falha	0	100%
Exportação muito lucrativa	33	56.6%
Energia de rede muito cara	12	84,2%

Tabela 3: Comparação de *policies*

Questão 4

A inclusão da variável meteorológica (W) no estado é fundamental porque o tempo é o motor da geração de energia no sistema. Ao removermos esta informação, o agente deixa de saber se a bateria terá uma tendência de carregamento (Sol) ou de estagnação (Nuvens) no passo seguinte.
Para testar este impacto, a matriz de transição foi simplificada para um espaço de 16 estados (5 níveis de bateria $\times$ 3 níveis de consumo + 1 estado de falha). A nova probabilidade de transição foi calculada como a média ponderada das transições originais:

$$P(B', C'|B, C, a) = \sum_{w \in \{0,1,2,3,4\}} P(w) \cdot P(B', C'|B, C, w, a)$$

A ausência de informação meteorológica altera os resultados de forma negativa por duas razões principais:

1. **Perda de Proatividade:** No modelo completo, se o agente sabe que está sol ($W = 1$), pode optar por exportar energia (AE) mesmo com bateria média, prevendo o seu carregamento rápido. Sem esta informação, o agente é forçado a adotar uma postura mais conservadora (acumular energia) para evitar o risco de falha caso o tempo esteja nublado.

2. **Eficiência de Custo:** O custo esperado total ($V(s)$) aumenta no modelo marginalizado. Como o agente decide com base em médias e não em certezas contextuais, ele acaba por comprar mais energia da rede (AC) por precaução ou perde oportunidades de lucro por não antecipar períodos de sol intenso.

A remoção da informação meteriológica degrada a performance da política ótima, o que resulta em custos operacionais superiores e menor aproveitamento do recurso solar.